SABIA · CALIDAD · CAPITAL SALUD

5. Corte del proyecto — 3 de noviembre de 2026

Estado de SABIA a esta fecha: qué tiene, para qué se hizo, cómo está construido y qué falta. Es un documento de corte: describe el proyecto **tal como está hoy** y reemplaza al corte del 28 de octubre, que se conserva como histórico. El detalle de cada parte vive en sus propios documentos:

Tema	Documento
Skills (8 de módulos Almera + 2 de entregables)	01-skills.md
Informes / dashboards	02-informes.md
Documentación de módulos de Almera	03-almera.md
Soporte técnico (arranque, diagnóstico, mantenimiento)	06-soporte-tecnico.md
Asistente RAG y ETL (operación)	`rag/README.md`
Rutas del sitio y menú compartido	`routes.md`

1. Resumen

SABIA (Sistema de Automatización, Base de información e Inteligencia Artificial) es el proyecto del área de Calidad de Capital Salud para que **nadie tenga que volver a ver una grabación de una hora para resolver una duda de Almera**, y para automatizar entregables repetitivos del área.

Tiene cinco piezas:

Pieza	Qué es	Estado
Documentación de Almera	Guías web + GuIA `.md` de 8 módulos	✓ Completa; Evaluaciones y Planes de mejora ampliados en este corte
Skills de Claude	8 skills de módulo + 2 de entregables	✓ Funcionales; los `.skill` de Evaluaciones y Planes de mejora quedaron atrás de su GuIA
Informes	2 dashboards que leen el listado maestro en el navegador	✓ Funcionales; KPIs personalizados corregidos y campos DEP en el del SGC
Asistente "Pregúntale a SABIA"	Chat web con RAG-lite sobre la documentación, vía OpenRouter	✓ Funcional en local; sigue pendiente publicarlo en el servidor del área
ETL de la carpeta compartida	Convierte Word/PDF/PPT/Excel del área en conocimiento para el asistente	✓ Funcional en local, ahora también con subida desde el chat

Lo que cambió desde el 28 de octubre

Área	Cambio
Arranque	`npm start` y `iniciar.bat` en la raíz, además de `rag\iniciar.ps1`. Ninguno exige cambiar la política de PowerShell del equipo.
Asistente	Botón "**Aportar un documento**": descarga la plantilla, elige el módulo, sube el archivo y muestra el semáforo al instante.
Asistente	Módulo nuevo "**SABIA (cómo alimentarlo)**": responde cómo agregar, actualizar o eliminar conocimiento. No acepta subidas.

Área	Cambio
Asistente	Módulo nuevo **"General"** para información de Almera que no es de un solo módulo (ingreso, navegación, conceptos comunes).
Asistente	El enrutador entiende **conjugaciones y plurales** ("¿cómo te alimento?" ya encuentra "alimentar").
Sitio	El servidor manda `Cache-Control: no-cache` en todo el sitio: un recargar normal ya trae el JavaScript nuevo.
Informes	Los **KPIs personalizados** ya no dan 0 por mayúsculas, tildes, espacios o decimales con coma, y sugieren los valores reales del Excel.
Informes	El del **SGC** suma **Seguimiento al estado** y **Profesional DEP** en filtros, gráficos, tabla, exportación y KPIs personalizados. El de Almera no cambia.
Almera	**Evaluaciones:** nueva sección *G · Configurar seguimientos y privilegios*.
Almera	**Planes de mejora:** nuevas secciones *03 · Dar seguimiento a un plan de mejora* y *A.4 · Privilegios de seguimiento*.
Conocimiento	Carpeta compartida con 2 documentos publicados: `Indicadores/crear-indicadores.docx` (🟡) y `General/Administracion_Usuarios.docx` (🟢).
Documentación	Este corte y la guía de soporte técnico.

---

2. Para qué se hizo

El problema

- La única fuente para resolver una duda de Almera eran **grabaciones de capacitación de 1 a 3 horas**, de las que dos minutos respondían la pregunta.
- Casi nadie usa todos los módulos, pero todos dependían de la misma grabación genérica.
- Las tareas repetitivas del área (presentaciones institucionales, diagramas en Bizagi, revisar el listado maestro) dependían de una o dos personas.

Los objetivos

1. **Autoservicio:** que cualquiera resuelva su duda de Almera en segundos, con la ruta exacta y los pasos documentados.
2. **No inventar:** si algo no está documentado o no está confirmado con soporte, el sistema lo dice en vez de suponer.
3. **Conocimiento vivo:** que el área pueda agregar y actualizar conocimiento sin depender de un desarrollador.
4. **Automatizar entregables** siguiendo los lineamientos institucionales.

Por qué un asistente propio, si ya existían las skills

Las skills solo funcionan para quien tiene **cuenta de Claude** y sabe instalarlas. El asistente web abre SABIA a **cualquier persona de la entidad desde el navegador**, sin cuenta ni instalación. Las skills siguen siendo útiles para quien trabaja en Claude, y las dos usan la misma documentación.

---

3. Qué tiene el proyecto hoy

3.1 Documentación de Almera (`almera/`)

8 módulos, cada uno en **tres copias del mismo contenido** que se sincronizan a mano: guía web (`index.html`), GuIA (`AI/*.md`) y skill (`AI/*.skill`).

Grupo	Módulos
Documentos	Gestión documental, Mapa de procesos (incluye SNC), Mecanismos de integración, Modelos de gestión
Evaluaciones	Evaluaciones / Auditorías, Indicadores, Planes de mejora
Proyectos	Proyectos

Novedades de este corte:

- **Evaluaciones → G · Configurar seguimientos y privilegios:** cómo habilitar en *Sistemas de referencia → Privilegios* a quien hará seguimientos (administración, consulta o adición de evaluación) y cómo comprobarlo.
- **Planes de mejora → 03 · Añadir o dar seguimiento:** entrar al plan, abrir la acción de mejora y registrar en «Seguimiento» o «Seguimientos de control».
- **Planes de mejora → A.4 · Privilegios de seguimiento:** qué hacer si no aparece el botón «Adicionar».

Más: árbol de navegación de Admin (`assets/almera-structure.md`), códigos de estructura organizacional y la guía para instalar las skills (`almera-IA/`). Detalle y pendientes en 03-almera.md.

3.2 Skills de Claude

- **8 skills de módulo** (`almera-*`): responden dudas con la GuIA del módulo.
- **2 skills de entregables:** `presentaciones-institucionales` (PPTX/HTML/PDF con la plantilla y paleta institucional) y `diagramas-flujo` (BPMN/PDF/PNG/JPG/SVG estilo Bizagi, con validación por colores).

⚠️ Los `.skill` de **Evaluaciones** y **Planes de mejora** no incluyen los pasos de seguimiento de este corte: hay que reempaquetarlos (01-skills.md §0). Detalle en 01-skills.md.

3.3 Informes (dashboards)

- **Informe de documentos Almera** (`almera/informe-documentos/`): KPIs y calidad de datos del export de Almera.
- **Control de documentos del SGC** (`almera/control-documentos-sgc/`): vigencia y actualización del listado maestro del SGC.

Los dos procesan el Excel **en el navegador** (nada sale del equipo) y permiten indicadores personalizados sin código.

Novedades de este corte:

- **Indicadores personalizados más tolerantes:** no importan mayúsculas, tildes ni espacios de más ("si" encuentra "SI " y "Sí"). En números sirve la coma o el punto decimal. El campo *Valor* sugiere los valores que trae el Excel cargado, y el panel no deja guardar "mayor que" o "menor que" con un valor que no sea número.
- **SGC, campos de la DEP:** *Seguimiento al estado del documento* (ACTUALIZADO, EN REVISIÓN, EN APROBACIÓN, EN ACTUALIZACIÓN…) y *Nombre profesional asignado de la DEP*, con filtros, dos gráficos nuevos, columnas en la tabla, exportación y campos en los KPIs personalizados.
- **SGC, "Requiere actualización" en dos versiones** para los KPIs personalizados: agrupada (SI / NO / Derogado / Otro) y con el texto tal cual del Excel ("Para derogar", "En actualización"…).
- Se corrigió el ordenamiento de las columnas *Tipo* y *Requiere actualización* en la tabla del SGC.

Detalle en 02-informes.md.

3.4 Asistente "Pregúntale a SABIA" (`rag/`)

- Chat en `/asistente/`, con la identidad visual de la portada.
- Responde con la **ruta exacta y los pasos**, avisa cuando algo está "pendiente de validar con soporte" y cita la fuente.
- Muestra en qué módulo buscó y qué secciones consultó. Tiene un selector para fijar el módulo a mano.
- Respuesta en *streaming* (va apareciendo mientras se escribe).
- **Nuevo · Aportar un documento:** botón que descarga la plantilla y el prompt de limpieza, sube el archivo a la subcarpeta correcta de la carpeta compartida, corre el ETL en ese momento y muestra el semáforo con sus notas. Pide confirmación si ya existe un archivo con el mismo nombre.
- **Nuevo · 10 módulos de conocimiento:** los 8 de Almera, **General** y **SABIA (cómo alimentarlo)**. Este último usa la guía `rag/conocimiento/alimentar-sabia.md` y está marcado `"uploads": false`: no aparece en el botón de subida ni se puede alimentar desde la carpeta.

3.5 ETL de la carpeta compartida (`rag/app/etl.py`)

- El área guarda un Word, PDF, PowerPoint, Excel o `.txt` en la subcarpeta de su módulo, o lo sube con el botón del chat.
- El servidor revisa la carpeta cada 5 minutos, lo convierte a Markdown limpio, le aplica un **semáforo** 🟢🟡🔴 y lo suma al asistente **sin reiniciar**.
- Deja un `ESTADO SABIA.txt` en la carpeta, con el resultado y qué corregir.
- La carpeta modelo (`rag/carpeta-compartida/`) trae `LEEME.txt`, un prompt para ordenar documentos con IA, una plantilla de Word y ahora la subcarpeta **General**.

Estado al corte:

Documento	Módulo	Semáforo	Nota
`Indicadores/crear-indicadores.docx`	Indicadores	🟡	Pocos títulos; se quitaron 6 textos de ejemplo de la plantilla
`General/Administracion_Usuarios.docx`	General	🟢	—

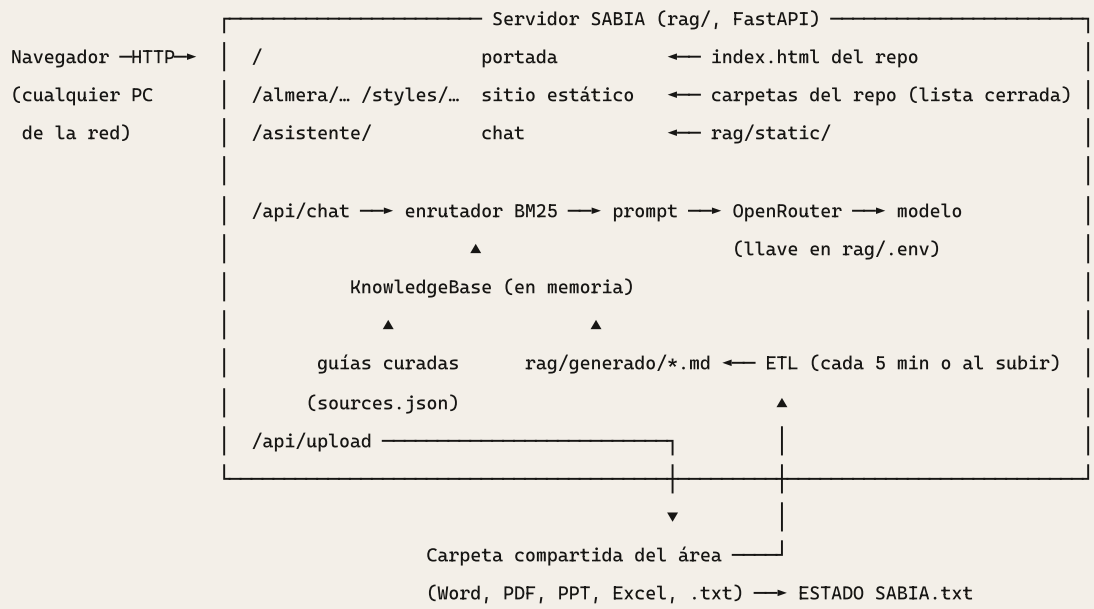
3.6 Sitio y navegación

- Portada (`index.html`) con 4 entradas: Almera, Agentes de IA, Control de documentos SGC y Pregúntale a SABIA.
- **Menú 1c** en todas las páginas (salvo los dos informes, por diseño), montado por `almera/assets/nav.js`. Detalle en `routes.md`.
- **Nuevo:** el servidor marca todo el sitio con `Cache-Control: no-cache`. El navegador revalida cada archivo (si no cambió, responde 304), así que ya no queda una página nueva con un `main.js` viejo, que era lo que dejaba filtros vacíos tras una actualización.

---

4. Arquitectura

4.1 Vista general



4.2 Dos formas de servir el sitio

Modo	Cómo	Qué funciona
Servidor SABIA (recomendado)	`npm start`, `iniciar.bat` o `rag\iniciar.ps1` → `http://127.0.0.1:8800/`	Todo: sitio, menú, asistente, subidas y ETL
Solo estático	`npx serve`, GitHub Pages o doble clic al HTML	Todo menos el asistente (su enlace da 404)

Funciona en los dos modos porque **todos los enlaces son relativos** y ninguno lleva puertos.

4.3 Qué pasa en cada pregunta

1. **El navegador envía** `POST /api/chat` con el historial de la conversación y, si se fijó, el módulo. El servidor no guarda conversaciones.
2. **Validar:** se toman los últimos 8 mensajes; el último debe ser del usuario y de máximo 4000 caracteres.
3. **Enrutar** (`knowledge.py`):
   - Une las dos últimas preguntas del usuario, para que "¿y cómo lo apruebo?" siga en el mismo módulo.
   - Las parte en palabras, quita palabras vacías y recorta terminaciones (`stem()`): "alimento", "alimentas" y "alimentarlo" cuentan igual.
   - Busca en un índice **BM25** de unas 400 secciones (títulos `#` – `###`) y suma los 3 mejores puntajes de cada módulo.
   - Elige el mejor módulo, y un segundo si saca al menos el 60 % del primero. Si se fijó un módulo, usa solo ese.
4. **Armar el prompt** (`prompts.py`): reglas + lista de módulos + árbol de navegación de Admin + **los documentos completos** de los módulos elegidos, cada uno dentro de `<documento>`. Si no caben en `MAX_CONTEXT_CHARS`, van primero los más relevantes.
5. **Llamar al modelo** (`llm.py`): POST a OpenRouter desde el servidor con *streaming*, temperatura 0,2 y `data_collection: deny`. La llave nunca llega al navegador.

6. **Responder:** eventos SSE en orden `meta` (módulos y fuentes), `delta` (texto), `error` si algo falla y `done`. El navegador pinta el Markdown con `marked` y lo limpia con `DOMPurify`.

El modelo **no lee archivos ni recuerda nada**: en cada pregunta el servidor le pega el texto relevante.

4.4 Qué hace el ETL

```
Extraer (MarkItDown) ──► Transformar (código, sin IA) ──► Validar (semáforo) ──► Cargar
```

- **Transformar:** quita imágenes, números de página, encabezados y pies repetidos (solo PDF y PPT), textos de ejemplo de la plantilla y secciones vacías; convierte en títulos los párrafos que son solo negrita y limpia los `NaN` de Excel.
- **Validar:**
  - 🔴 No publica: plantilla sin llenar, escaneado o casi vacío, transcripción de reunión, texto desarmado, largo sin títulos, formato antiguo, carpeta que no es un módulo o archivo suelto.
  - 🟡 Publica con aviso.
  - 🟢 Publica.
- **Cargar:** el `.md` va a `rag/generado/<módulo>/` y el reporte a la carpeta compartida. **Nunca mueve ni modifica los originales.** Solo reprocesa lo que cambió (fecha y tamaño), salvo que suba `ETL_VERSION`.
- **Disparadores:** el ciclo periódico (`ETL_INTERVAL_SECONDS`) y cada subida por `/api/upload`. Un candado (`etl_lock`) evita que corran dos a la vez.

4.5 Mapa del repositorio

```
almera-docs/
├── index.html                Portada de SABIA
├── package.json              npm start → rag\iniciar.ps1 (nuevo)
├── iniciar.bat               Doble clic → rag\iniciar.ps1 (nuevo)
├── routes.md                 Rutas del sitio y menú
├── docs/                     Documentación de traspaso, cortes y soporte técnico
├── styles/                   Estilos de la portada
├── almera/                   Documentación de Almera, informes y nav.js
├── calidad-ai-agents/        Skills de entregables
└── rag/                      Servidor SABIA
    ├── app/
    │   ├── main.py           Servidor: sitio + chat + subidas + ciclo del ETL
    │   ├── knowledge.py      Base de conocimiento, índice BM25, enrutamiento
    │   ├── etl.py            Carpeta compartida → Markdown con semáforo
    │   ├── llm.py            Cliente de OpenRouter
    │   ├── prompts.py        Reglas del asistente
    │   └── config.py         Lee rag/.env
    ├── conocimiento/         Guía del módulo "SABIA (cómo alimentarlo)" (nuevo)
    ├── static/               Interfaz del chat
    ├── carpeta-compartida/   Modelo de la carpeta del área (LEEME, prompt, plantilla)
    ├── generado/             Salida del ETL (no se sube a Git)
    ├── sources.json          Catálogo de módulos y guías curadas
    ├── .env.example          Plantilla de configuración (el .env real no se sube)
    └── iniciar.ps1           Arranque en Windows
```

---

5. Stack tecnológico

Capa	Tecnología	Para qué
Frontend	HTML, CSS y JavaScript plano (sin framework, sin build)	Sitio, informes, chat y menú
	DM Sans + JetBrains Mono (Google Fonts)	Tipografía de SABIA
	Chart.js, SheetJS (`vendor/`)	Gráficos y lectura de Excel en los informes
	marked 12.0.2, DOMPurify 3.1.6 (`rag/static/vendor/`)	Markdown seguro en el chat
Backend	Python 3.13	Lenguaje del servidor
	FastAPI 0.115 + Uvicorn 0.34	Servidor web, API y archivos estáticos
	httpx 0.28	Llamadas a OpenRouter con *streaming*
	python-dotenv 1.1	Configuración y llave en `rag/.env`
	truststore 0.10	Usa los certificados de Windows (la red inspecciona TLS)
	MarkItDown 0.1.9 (Microsoft)	Word/PDF/PPT/Excel → Markdown en el ETL
Arranque	PowerShell (`iniciar.ps1`), `.bat`, npm (opcional)	Crear el entorno y levantar el servidor
IA	OpenRouter	Acceso a modelos; se cambia el modelo sin tocar código
	`anthropic/claude-haiku-5.5` (por defecto)	Modelo del asistente: barato, buen español, sigue reglas
	Claude Agent Skills (`.skill`)	Las 10 skills del proyecto
Búsqueda	BM25 propio en Python puro, con recorte de terminaciones	Enrutar preguntas sin base vectorial
Datos	Archivos Markdown en el repo y en la carpeta compartida	No hay base de datos
Herramientas	Git + GitHub (`faazdy/almera-docs`), Claude Code, Claude Design	Desarrollo, diseño y pruebas

Lo que deliberadamente NO se usó: base de datos, base vectorial, embeddings, framework de frontend, LangChain u otro framework de LLM, Docker. El volumen actual no los justifica y cada uno suma mantenimiento (ver §6).

---

6. Cómo se hizo: decisiones y por qué

Decisión	Por qué	Cuándo revisarla
RAG-lite (enrutar + inyectar el módulo completo) en vez de RAG clásico con embeddings	Todo el conocimiento son unos 236 KB (unos 60 000 tokens) y el módulo más grande pesa 33 KB. Partir en fragmentos corta los procedimientos paso a paso, que es el peor error posible en este dominio.	Si el conocimiento pasa de unos 150 000 tokens o de cientos de documentos. El punto de cambio es `KnowledgeBase.route()`.
BM25 léxico para enrutar	Sin dependencias, sin costo, determinista y fácil de depurar.	Si el enrutador se equivoca seguido con preguntas reales.

Decisión	Por qué	Cuándo revisarla
Recorte de terminaciones propio en vez de una librería de *stemming*	Resolvía el caso real ("¿cómo te alimento?") sin dependencias. Se midió con los títulos de las guías: perdió 4 de 291 aciertos, a cambio de entender conjugaciones.	Si aparecen preguntas mal enrutadas por palabras que se confunden al recortarlas.
Módulo de autoayuda ("SABIA (cómo alimentarlo)") en vez de reglas en el prompt	Las preguntas sobre el propio asistente siguen el mismo camino que las demás y la guía se edita como cualquier `.md`.	—
`"uploads": false` por módulo	Evita que alguien suba documentos a un módulo cuyo contenido debe controlar el equipo técnico.	—
Subida por el chat que reutiliza la carpeta compartida	Un solo lugar de verdad: lo subido queda en la carpeta, igual que si se copiara a mano, y pasa por el mismo ETL.	—
`no-cache` **en el sitio** en vez de versionar archivos (`main.js?v=…`)	No hay build que ponga versiones; con `no-cache` el navegador revalida y, si no cambió, recibe un 304 sin costo.	Si el sitio se sirve desde otro servidor web: configurar allí la misma cabecera.
OpenRouter en vez de un proveedor fijo	Permite cambiar de modelo con una línea del `.env` y comparar costo y calidad.	—
Un solo servidor para sitio + chat	Con dos servidores, los enlaces entre sitio y chat necesitaban puertos fijos.	—
Lista cerrada de carpetas publicadas (`SITE_DIRS`)	Montar la raíz expondría `rag/.env` (la llave) y `.git`.	Al agregar una carpeta de primer nivel.
El ETL no mueve ni edita los originales	Mover archivos en una carpeta de red que otros usan genera conflictos con archivos abiertos.	—
Revisión periódica (polling) en vez de detección instantánea	Las notificaciones de cambios no son confiables en carpetas de red.	Bajar a 60 s si se quiere respuesta más rápida.
`truststore` en vez de desactivar SSL	La red corporativa inspecciona TLS con un certificado propio.	—

Cómo se construyó (este corte)

Con Claude Code, en sesiones de trabajo posteriores al corte del 28 de octubre:

1. **Arranque simple:** `package.json` (`npm start`) e `iniciar.bat`.
2. **Autoayuda:** guía `alimentar-sabia.md` y módulo "SABIA (cómo alimentarlo)"; módulo General.
3. **Enrutador:** recorte de terminaciones, medido con los títulos de las guías y un set de preguntas de prueba.
4. **Informes:** KPIs personalizados verificados contra el Excel real con un arnés de Node que ejecuta el JavaScript del informe; campos DEP en el del SGC, con conteos comparados contra el Excel.
5. **Caché:** `no-cache` en el servidor tras detectar una página nueva con un `main.js` viejo.
6. **Almera:** pasos de seguimiento en Evaluaciones y Planes de mejora (GuIA y guía web).

Commits en `master`: `1f286a7`, `f0b1e22`, `e2a6765`, `b277b33`, `2b4e75f`.

---

7. Seguridad

- **Llave de OpenRouter:** solo en `rag/.env`, que está en `.gitignore`. Nunca llega al navegador.

- **Qué publica el servidor:** solo `index.html`, `styles/`, `almera/` y `calidad-ai-agents/`. Lo demás da 404, incluidos los intentos con `../` codificado.
- **Privacidad de las preguntas:** `data_collection: deny` hace que OpenRouter solo use proveedores que no guardan ni entrenan con los datos. Aun así, la regla es **no pegar datos personales ni de pacientes** (ver `calidad-ai-agents/SEGURIDAD.md`).
- **Respuestas:** el Markdown del modelo se sanitiza con DOMPurify antes de mostrarse.
- **Límites:** preguntas de máximo 4000 caracteres, máximo 8 mensajes de historial y archivos de máximo 20 MB.
- **Subidas:** solo formatos del ETL; se guarda únicamente el nombre del archivo (sin rutas) dentro de la carpeta del módulo; no se puede subir a módulos con `"uploads": false`.
- **Historial en el navegador:** como el servidor no guarda conversaciones, un usuario técnico podría enviar un historial inventado. No da acceso a nada más que a gastar créditos: la llave y los documentos siguen en el servidor.
- **Informes:** el Excel se procesa en el navegador y no sale del equipo. El listado del SGC trae nombres de profesionales de la DEP: no subirlo al repositorio.
- ⚠️ **El asistente y las subidas no tienen autenticación.** Mientras escuche en `127.0.0.1` solo lo usa ese equipo. Con `HOST=0.0.0.0`, cualquiera en la red podría preguntar (gastar créditos) y **publicar documentos**. Hay que configurar un **límite de gasto** en la llave de OpenRouter antes de abrirlo.

---

8. Operación y costos

Arrancar (desde la raíz del repo): `npm start`, doble clic en `iniciar.bat` o `cd rag; .\iniciar.ps1`. La primera vez crea el entorno, instala dependencias y crea `rag/.env`; hay que poner la llave y volver a arrancar. El paso a paso, los síntomas y las soluciones están en 06-soporte-tecnico.md.

Variable (`rag/.env`)	Por defecto	Qué hace
`OPENROUTER_API_KEY`	—	Llave de OpenRouter
`OPENROUTER_MODEL`	`anthropic/claude-haiku-5.5`	Modelo del asistente
`OPENROUTER_DENY_DATA_COLLECTION`	`true`	Solo proveedores que no guardan datos
`HOST` / `PORT`	`127.0.0.1` / `8800`	Dónde escucha el servidor
`MAX_CONTEXT_CHARS`	`120000`	Tope de documentación por pregunta
`KNOWLEDGE_DIR`	`carpeta-compartida`	Carpeta del ETL. En producción, `\\servidor\Calidad\SABIA` **sin comillas**
`ETL_INTERVAL_SECONDS`	`300`	Cada cuánto se revisa la carpeta
`MAX_UPLOAD_MB`	`20`	Tamaño máximo de un archivo subido por el chat

Costo estimado: entre 8 y 17 mil tokens de entrada por pregunta, unos **US$0,002 por pregunta** con Haiku 5.5. Mil preguntas al mes cuestan alrededor de US$2.

---

9. Pendientes y riesgos

Para dejar el asistente en producción (Fase 2) — sin cambios desde el corte anterior

- [ ] **Definir con TI dónde corre el servidor:** un equipo siempre encendido y con acceso a la carpeta de red.
- [ ] **Permisos de la carpeta:** el servidor lee la carpeta y escribe `ESTADO SABIA.txt` y las subidas del botón. Las personas que publican tienen escritura en las subcarpetas.
- [ ] **Abrir el puerto 8800** en la red interna si los compañeros van a entrar desde su PC.
- [ ] **Autenticación básica** antes de abrirlo a la red, para el chat y sobre todo para `/api/upload`.
- [ ] **Límite de gasto** en la llave de OpenRouter.
- [ ] **Copiar** `rag/carpeta-compartida/` al servidor y apuntar `KNOWLEDGE_DIR` a esa ruta.
- [ ] **Validar la calidad de las respuestas** con un set de preguntas reales del área por módulo.

Nuevos en este corte

- [ ] **Reempaquetar los** `.skill` **de Evaluaciones y Planes de mejora** con los pasos de seguimiento. Hoy la GuIA y la guía web los tienen; la skill no.
- [ ] **Corregir la GuIA de Planes de mejora:** en "Añadir o dar seguimiento a un plan de mejora", el texto de *Cuándo se usa* es el de la sección siguiente (configurar el sistema de referencia). La guía web ya tiene el texto correcto.
- [ ] **Confirmar el prefijo de las rutas nuevas:** la GuIA dice `Evaluaciones → …` y la guía web `Admin → Evaluaciones → …`, como el resto del módulo.
- [ ] **Mejorar** `crear-indicadores.docx` (🟡): usar estilos Título 1 y Título 2 y borrar los textos de ejemplo de la plantilla.
- [ ] **Llenar el módulo General:** hoy tiene un solo documento (`Administracion_Usuarios.docx`).

Mejoras identificadas

- [ ] Revisar la carpeta cada **60 s** en vez de 300 (sin costo).
- [ ] Registrar las preguntas que el asistente no pudo responder, para saber qué documentar.
- [ ] **Pruebas automatizadas** del ETL, del enrutador y de los informes. Las de este corte fueron scripts de un solo uso (arnés de Node para los informes y una evaluación de enrutamiento con los títulos de las guías); conviene dejarlas en el repo.

Riesgos y deudas que vienen de antes (ver 01–03)

- `diagramas-flujo`: el `.skill` es la única copia completa del generador; las fuentes del repo están desactualizadas (01-skills.md §3.4).
- **Tres copias por módulo de Almera** (guía web, GuIA, skill) que se sincronizan a mano. Este corte ya muestra el desfase en dos módulos.
- **Dudas abiertas con soporte de Almera** en varios módulos (03-almera.md).
- **Documentos desactualizados:** el `README.md` raíz y `sabia.MD` todavía describen SABIA como sitio 100 % estático, sin servidor.

---

10. Próximos pasos sugeridos (en orden)

1. **Sincronizar Evaluaciones y Planes de mejora** (GuIA corregida → reempaquetar `.skill`).
2. **Fase 2:** publicar el servidor en la red del área con TI, con autenticación y límite de gasto (§9).

3. **Piloto con usuarios reales** de uno o dos módulos, registrando las preguntas sin respuesta.
4. **Reconciliar** `diagramas-flujo` (riesgo de perder el generador).
5. **Actualizar el README raíz y** `sabia.MD` con el asistente y la arquitectura de servidor.
6. Ideas del `to-do`: skills para ChatGPT Pro, agente local con LM Studio y **RAG para la DEP**. Este último puede reutilizar casi todo `rag/`: cambian `sources.json`, la carpeta compartida y el prompt.

---

11. Glosario

Término	Significado
RAG	*Retrieval-Augmented Generation*: buscar la información relevante y dársela al modelo junto con la pregunta, para que responda con datos reales y no de memoria.
RAG-lite	La variante de SABIA: en vez de buscar fragmentos, elige el módulo y le pasa su documentación completa.
BM25	Algoritmo clásico de búsqueda por palabras clave (el de los buscadores tradicionales).
Stemming / recorte de terminaciones	Quitar la terminación de una palabra para que sus conjugaciones y plurales cuenten como la misma.
ETL	*Extract, Transform, Load*: extraer el contenido de un archivo, limpiarlo y cargarlo donde se usa.
GuIA	El documento `.md` de referencia de cada módulo de Almera.
Skill	Paquete `.skill` que Claude carga cuando el pedido lo requiere.
OpenRouter	Servicio que da acceso a muchos modelos de IA con una sola llave.
Streaming / SSE	La respuesta llega por partes mientras se genera, en vez de esperar a que termine.
Semáforo	🟢 publicado · 🟡 publicado con advertencias · 🔴 no publicado.